Technická univerzita v Košiciach

Fakulta elektrotechniky a informatiky

Predmet: Moderné prístupy v optimalizácii

Artificial Protozoa Optimizer

Zadanie č. 1

Autori:
Volodymyr Ihnatov
Volodymyr Vulchyn
Nika Meskhi

Študijný program:
Umelá inteligencia

Košice, 2026

Abstrakt

Táto práca sa zaoberá analýzou a experimentálnym riešením optimalizačnej úlohy návrhu tlačnej pružiny pomocou algoritmu Artificial Protozoa Optimizer (APO) a jeho siedmich modifikácií. Cieľom je porovnať kvalitu a stabilitu riešení pri rovnakom výpočtovom rozpočte. Každý algoritmus bol testovaný v 30 behoch s rozpočtom 10 000 vyhodnotení fitness funkcie na jeden beh.

Najlepšie jednotlivé riešenie dosiahol variant APO-PSO, zatiaľ čo APO-wr-DE dosiahol najlepšiu priemernú hodnotu a najnižšiu smerodajnú odchýlku. Štatistické porovnanie pomocou Wilcoxonovho testu s Holmovou korekciou preukázalo významné zlepšenie variantov APO-DE a APO-wr-DE oproti základnému APO. Výsledky naznačujú prínos vybraných modifikácií pre skúmanú optimalizačnú úlohu.

Obsah

1 Úvod **2**

2 Optimalizačný problém **2**
2.1 Definícia a charakteristika problému 2
2.2 Rozhodovacie premenné a priestor riešení 2
2.3 Účelová funkcia a obmedzenia 2

3 Artificial Protozoa Optimizer **3**
3.1 Princíp algoritmu APO 3
3.2 Mechanizmy vyhľadávania 3

4 Implementácia a navrhnuté modifikácie **4**
4.1 Architektúra implementácie 4
4.2 Modifikácie algoritmu APO 4
4.3 Rozdiely oproti pôvodnému článku 4

5 Experimentálna metodológia **4**
5.1 Nastavenie experimentov 4
5.2 Hodnotiace metriky a štatistické testy 5
5.3 Reprodukovateľnosť experimentov 5

6 Výsledky a porovnanie **5**
6.1 Numerické výsledky 5
6.2 Analýza konvergencie a štatistické porovnanie 6
6.3 Porovnanie s výsledkami autorov 7

7 Diskusia a obmedzenia **7**

8 Záver **8**

1 Úvod

Optimalizácia zohráva významnú úlohu pri riešení technických a inžinierskych problémov, pri ktorých je potrebné nájsť čo najlepšie riešenie pri dodržaní stanovených obmedzení. Mnohé optimalizačné úlohy sú nelineárne a obsahujú viacero lokálnych extrémov, preto sa na ich riešenie využívajú aj metaheuristické algoritmy.

Jedným z takýchto algoritmov je Artificial Protozoa Optimizer (APO), ktorý predstavili Wang a kol. v roku 2024 [1]. Algoritmus je inšpirovaný správaním jednobunkových organizmov a využíva mechanizmy získavania potravy, dormancie a reprodukcie na vyhľadávanie kvalitných riešení. Jeho účinnosť bola v pôvodnej štúdii overená na štandardných testovacích funkciách a viacerých inžinierskych optimalizačných úlohách.

Cieľom tejto práce je analyzovať optimalizačný problém návrhu tlačnej pružiny a experimentálne porovnať pôvodný algoritmus APO so siedmimi jeho modifikáciami. Navrhnuté varianty využívajú váhy založené na poradí kandidátov, diferenciálnu evolúciu, lokálne vyhľadávanie a optimalizáciu rojom častíc. Jednotlivé algoritmy sú porovnané pri rovnakom výpočtovom rozpočte s dôrazom na kvalitu nájdených riešení, ich stabilitu a priebeh konvergencie.

2 Optimalizačný problém

2.1 Definícia a charakteristika problému

V tejto práci sa rieši optimalizačná úloha návrhu tlačnej vinutej pružiny (angl. tension/compression spring design), ktorá patrí medzi inžinierske problémy skúmané v pôvodnom článku o algoritme APO [1]. Cieľom je minimalizovať hmotnosť pružiny prostredníctvom vhodnej voľby jej geometrických parametrov pri súčasnom dodržaní konštrukčných a mechanických obmedzení.

Z matematického hľadiska ide o jednokriteriálnu, minimalizačnú, nelineárnu a spojitú optimalizačnú úlohu s obmedzeniami. Účelová funkcia a obmedzenia sú deterministické a počas optimalizácie sa nemenia, preto je úloha statická. Matematický model je explicitne definovaný, pričom algoritmus APO využíva hodnoty účelovej funkcie bez potreby výpočtu jej derivácií.

2.2 Rozhodovacie premenné a priestor riešení

Kandidátne riešenie je reprezentované vektorom troch reálnych rozhodovacích premenných:

$$\mathbf{x} = (d, D, N), \tag{1}$$

kde d predstavuje priemer drôtu pružiny, D stredný priemer vinutia a N počet aktívnych závitov. Hoci počet závitov môže mať v praxi diskrétny charakter, v použitej matematickej formulácii sa považuje za spojitú premennú.

Hranice rozhodovacích premenných sú v implementácii stanovené nasledovne:

$$\begin{aligned} 0{,}05 \leq d \leq 2{,}0, \\ 0{,}25 \leq D \leq 1{,}3, \\ 2{,}0 \leq N \leq 15{,}0. \end{aligned} \tag{2}$$

Priestor vyhľadávania tvorí trojrozmerná oblasť $\Omega = [0{,}05; 2{,}0] \times [0{,}25; 1{,}3] \times [2{,}0; 15{,}0]$. Nie každé riešenie z tejto oblasti je však prípustné, pretože musí zároveň spĺňať mechanické a konštrukčné obmedzenia uvedené v nasledujúcej podkapitole.

2.3 Účelová funkcia a obmedzenia

Cieľom optimalizácie je minimalizovať funkciu, ktorá vyjadruje spotrebu materiálu pri návrhu pružiny. V použitej implementácii má účelová funkcia tvar

$$\min_{\mathbf{x}} f(\mathbf{x}) = (N+2)Dd^2. \tag{3}$$

Optimalizačná úloha je podmienená štyrmi nelineárnymi obmedzeniami, ktoré musia spĺňať prípustné riešenia:

$$g_1(\mathbf{x}) = 1 - \frac{D^3 N}{71785d^4} \leq 0, \tag{4}$$

$$g_2(\mathbf{x}) = \frac{4D^2 - dD}{12566(Dd^3 - d^4)} + \frac{1}{5108d^2} - 1 \leq 0, \tag{5}$$

$$g_3(\mathbf{x}) = 1 - \frac{140{,}45d}{D^2 N} \leq 0, \tag{6}$$

$$g_4(\mathbf{x}) = \frac{d+D}{1{,}5} - 1 \leq 0. \tag{7}$$

Keďže algoritmus APO pracuje s hodnotou fitness, porušenie obmedzení sa zohľadňuje pomocou penalizačnej funkcie

$$F(\mathbf{x}) = f(\mathbf{x}) + 10^6 \sum_{i=1}^{4} \left[\max(0, g_i(\mathbf{x}))\right]^2. \tag{8}$$

Ak kandidátne riešenie spĺňa všetky obmedzenia, penalizácia je nulová a platí $F(\mathbf{x}) = f(\mathbf{x})$. V opačnom prípade sa fitness zvýši podľa veľkosti porušených obmedzení. Algoritmus minimalizuje penalizovanú hodnotu $F(\mathbf{x})$.

3 Artificial Protozoa Optimizer

3.1 Princíp algoritmu APO

Artificial Protozoa Optimizer (APO) je populačný stochastický metaheuristický algoritmus, ktorý navrhli Wang a kol. [1]. Je inšpirovaný správaním jednobunkových organizmov, najmä euglén, pri získavaní potravy, prežívaní nepriaznivých podmienok a rozmnožovaní.

Každý jedinec populácie predstavuje kandidátne riešenie optimalizačnej úlohy, reprezentované vektorom rozhodovacích premenných. Populácia sa inicializuje náhodne v rámci stanovených hraníc. V každej iterácii sa jedince zoradia podľa hodnoty fitness a vytvárajú nové kandidátne riešenia pomocou mechanizmov získavania potravy, dormancie a reprodukcie. Nové riešenie nahradí pôvodné iba vtedy, ak dosahuje lepšiu hodnotu fitness.

3.2 Mechanizmy vyhľadávania

Získavanie potravy (*foraging*) zahŕňa dva režimy. Autotrofný režim umožňuje preskúmavať rôzne oblasti priestoru riešení na základe vzájomných pozícií jedincov. Heterotrofný režim podporuje vyhľadávanie v okolí aktuálneho riešenia. Pri aktualizácii pozícií sa využívajú váhy odvodené z hodnôt fitness a informácie o poradí jedincov v populácii.

Dormancia (*dormancy*) predstavuje mechanizmus, pri ktorom sa vybranému jedincovi vytvorí nové náhodné riešenie v priestore vyhľadávania. Tento proces podporuje diverzitu populácie a pomáha predchádzať predčasnej konvergencii.

Reprodukcia (*reproduction*) vytvára nové kandidátne riešenie náhodnou zmenou vybraných súradníc existujúceho jedinca. Umožňuje tak preskúmavať ďalšie riešenia v nadväznosti na aktuálnu populáciu.

Pravdepodobnosti jednotlivých mechanizmov sa menia v závislosti od iterácie alebo poradia jedinca v populácii. Algoritmus tak kombinuje prieskum nových oblastí (*exploration*) s intenzívnejším vyhľadávaním sľubných riešení (*exploitation*).

4 Implementácia a navrhnuté modifikácie

4.1 Architektúra implementácie

Riešenie bolo implementované v jazyku Python. Knižnica NumPy sa využíva na numerické výpočty a prácu s populáciou kandidátnych riešení, SciPy na štatistické vyhodnotenie experimentov a Matplotlib na vizualizáciu výsledkov.

Základ algoritmu APO je sústredený v súbore `apo.py`, pričom jednotlivé modifikácie sú dostupné prostredníctvom samostatných modulov. Optimalizačná úloha návrhu pružiny je definovaná v súbore `spring_design.py`, ktorý obsahuje účelovú funkciu, obmedzenia a výpočet penalizovanej hodnoty fitness.

Experimenty sa spúšťajú prostredníctvom súboru `run_experiments.py`, ktorý zároveň ukladá výsledky do CSV súborov.

4.2 Modifikácie algoritmu APO

Okrem základného algoritmu APO bolo implementovaných sedem variantov, ktorých cieľom je preskúmať vplyv rôznych vyhľadávacích mechanizmov na kvalitu a stabilitu optimalizácie.

Variant **APO-wr** nahrádza pôvodné váhy odvodené z hodnôt fitness váhami založenými na poradí jedincov v populácii.

Variant **APO-DE** využíva operátory diferenciálnej evolúcie na vytváranie nových kandidátnych riešení.

Variant **APO-LS** využíva lokálne vyhľadávanie v okolí najlepšieho riešenia na vytváranie kandidátov pre časť najhoršie hodnotených jedincov.

Variant **APO-PSO** využíva aktualizáciu pozícií inšpirovanú optimalizáciou rojom častíc, s informáciou o osobnom a globálnom najlepšom riešení.

Ďalšie tri varianty, **APO-wr-DE**, **APO-wr-LS** a **APO-wr-PSO**, kombinujú váhy založené na poradí s príslušným vyhľadávacím mechanizmom. Upravené operátory nahrádzajú generovanie vybraných kandidátov v rámci existujúcej iterácie, takže nezvyšujú počet vyhodnotení fitness.

4.3 Rozdiely oproti pôvodnému článku

Na rozdiel od pôvodnej štúdie, ktorá skúmala APO na viacerých testovacích a inžinierskych úlohách, sa táto práca sústreďuje na optimalizáciu návrhu tlačnej pružiny. Hlavným rozšírením je porovnanie pôvodného APO so siedmimi modifikovanými variantmi. Základný algoritmus využíva váhy podľa hodnôt fitness, zatiaľ čo vybrané modifikácie menia spôsob váhovania alebo generovania kandidátnych riešení.

Experimenty boli uskutočnené s menším výpočtovým rozpočtom než v pôvodnej štúdii. Na zabezpečenie férového porovnania však všetkých osem implementovaných variantov používa rovnakú optimalizačnú úlohu, fitness funkciu a počet jej vyhodnotení. Podrobné nastavenie experimentov je uvedené v nasledujúcej kapitole.

5 Experimentálna metodológia

5.1 Nastavenie experimentov

Experimenty boli vykonané na úlohe optimalizácie návrhu tlačnej pružiny s cieľom porovnať pôvodný algoritmus APO so siedmimi modifikovanými variantmi. Všetkých osem algoritmov používalo rovnakú účelovú funkciu, obmedzenia, priestor riešení a výpočtový rozpočet.

Pre každý algoritmus sa uskutočnilo 30 nezávislých spustení s populáciou 100 jedincov a 100 generáciami vrátane inicializácie. Jedno spustenie zahŕňalo 10 000 vyhodnotení fitness funkcie. Parametre APO boli nastavené na $np = 1$ a $pf_{\max} = 0{,}1$.

V modifikáciách sa operátor DE aplikoval na 20 % kandidátov s faktorom diferenciálnej mutácie $F_{\mathrm{DE}} = 0{,}5$ a pravdepodobnosťou kríženia $CR = 0{,}9$. Lokálne vyhľadávanie sa používalo pre 10 % populácie so základnou mierkou perturbácie 0,1. Mechanizmus PSO sa aplikoval na 10 % kandidátov. Kombinované varianty využívali príslušné nastavenia spolu s váhami založenými na poradí jedincov.

5.2 Hodnotiace metriky a štatistické testy

Kvalita algoritmov sa hodnotila na základe penalizovanej hodnoty fitness dosiahnutej na konci každého spustenia. Pre jednotlivé algoritmy sa vypočítala najlepšia a najhoršia hodnota, aritmetický priemer, medián a výberová smerodajná odchýlka z 30 behov.

Okrem kvality riešení sa sledovala konvergencia najlepšej nájdenej hodnoty fitness v závislosti od počtu jej vyhodnotení. Prípustnosť riešení sa posudzovala podľa celkového porušenia obmedzení s toleranciou 10^{-8}. Podiel prípustných finálnych riešení bol vyjadrený metrikou *feasible rate*.

Na porovnanie dvojíc algoritmov sa použil obojstranný párový Wilcoxonov test. Pri celkovo 28 párových porovnaniach sa p-hodnoty upravili Holmovou korekciou na hladine významnosti $\alpha = 0{,}05$.

5.3 Reprodukovateľnosť experimentov

Na zabezpečenie reprodukovateľnosti boli použité pevne určené počiatočné stavy generátora pseudonáhodných čísel. Pre k-té spustenie, kde $k = 1, \ldots, 30$, bol použitý seed

$$s_k = 2022 + 7(k - 1). \tag{9}$$

Pred každým spustením algoritmu bol generátor náhodných čísel inicializovaný príslušnou hodnotou seed. Všetky varianty tak boli testované s rovnakou sadou 30 počiatočných stavov.

Experimenty možno spustiť skriptom `run_experiments.py`. Výsledky sa ukladajú do súborov `runs.csv`, `convergence.csv`, `summary.csv` a `statistics.csv`. Návod na prípravu prostredia a spustenie experimentov je uvedený v súbore `README.md` projektu.

6 Výsledky a porovnanie

6.1 Numerické výsledky

Experimenty pozostávali z 30 behov pre každý z ôsmich algoritmov. Tabuľka 1 uvádza najlepšiu dosiahnutú hodnotu, priemer a smerodajnú odchýlku penalizovanej fitness funkcie. Nižšie hodnoty predstavujú lepšie riešenia.

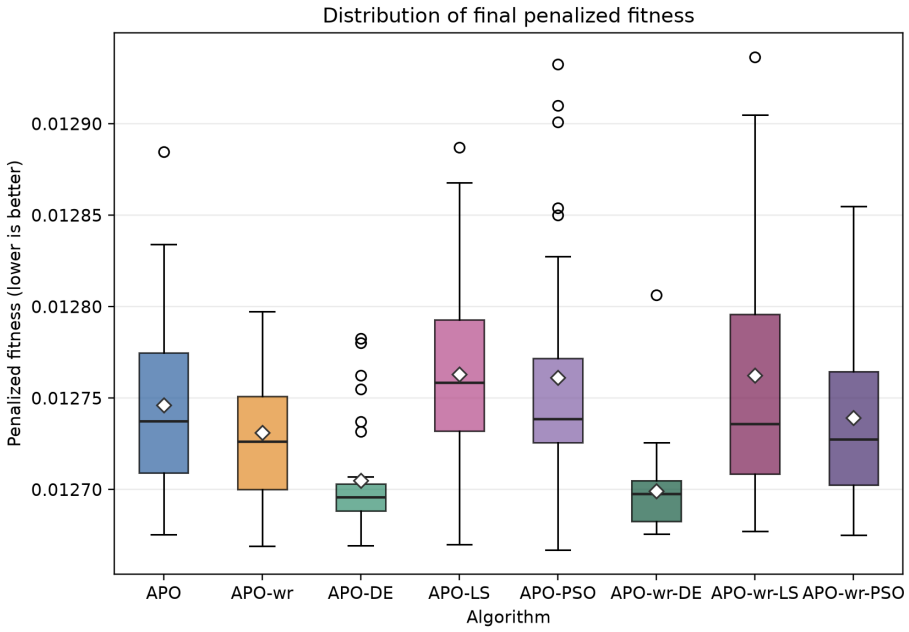
Tabuľka 1: Výsledky optimalizácie pružiny z 30 behov.

Algoritmus	Najlepšia	Priemer	Sm. odch.
APO	0.01267536	0.01274621	0.00004970
APO-wr	0.01266923	0.01273098	0.00003680
APO-DE	0.01266934	0.01270478	0.00002991
APO-LS	0.01267009	0.01276302	0.00005543
APO-PSO	**0.01266711**	0.01276117	0.00006869
APO-wr-DE	0.01267569	**0.01269914**	**0.00002467**
APO-wr-LS	0.01267715	0.01276240	0.00007676
APO-wr-PSO	0.01267507	0.01273928	0.00004889

Najlepšiu jednotlivú hodnotu fitness dosiahol algoritmus APO-PSO (0.01266711). Najlepší priemer (0.01269914) a zároveň najnižšiu smerodajnú odchýlku dosiahol variant APO-wr-DE.

Základný APO dosiahol priemernú hodnotu 0.01274621. Všetkých osem algoritmov dosiahlo 100 % prípustných finálnych riešení pri použitej tolerancii obmedzení.

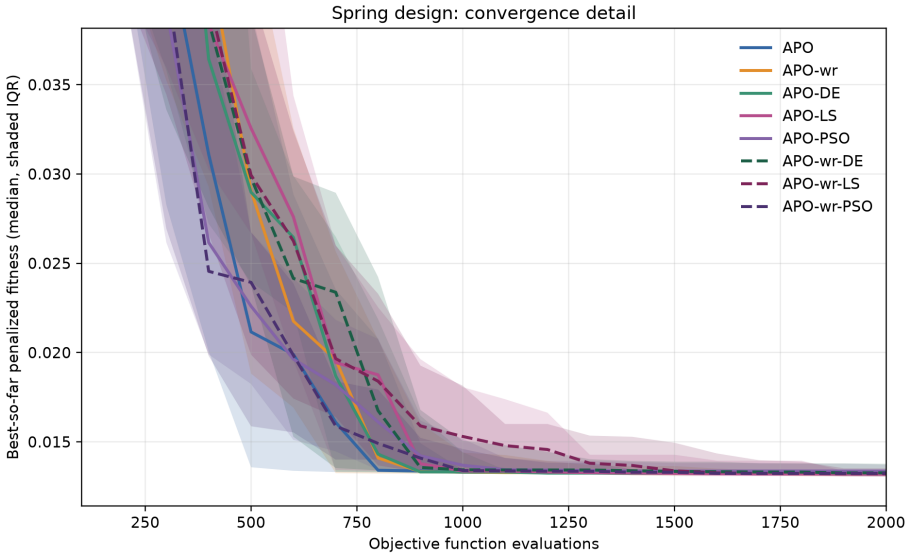
Rozdelenie finálnych hodnôt fitness znázorňuje obrázok 1. Krabicové diagramy umožňujú porovnať medián a variabilitu výsledkov jednotlivých algoritmov. Variant APO-wr-DE dosahuje nízke finálne hodnoty s relatívne malým rozptylom, zatiaľ čo niektoré varianty s mechanizmami LS a PSO vykazujú vyššiu variabilitu.



Obr. 1: Rozdelenie finálnych hodnôt fitness ôsmich algoritmov počas 30 behov.

6.2 Analýza konvergencie a štatistické porovnanie

Obrázok 2 zobrazuje priebeh konvergencie počas prvých 2 000 vyhodnotení fitness funkcie. Krivky predstavujú medián najlepšej dosiahnutej hodnoty z 30 behov a tieňované oblasti interval medzi 25. a 75. percentilom.



Obr. 2: Detail konvergencie ôsmich algoritmov počas prvých 2 000 vyhodnotení fitness; medián a interval medzi 25. a 75. percentilom.

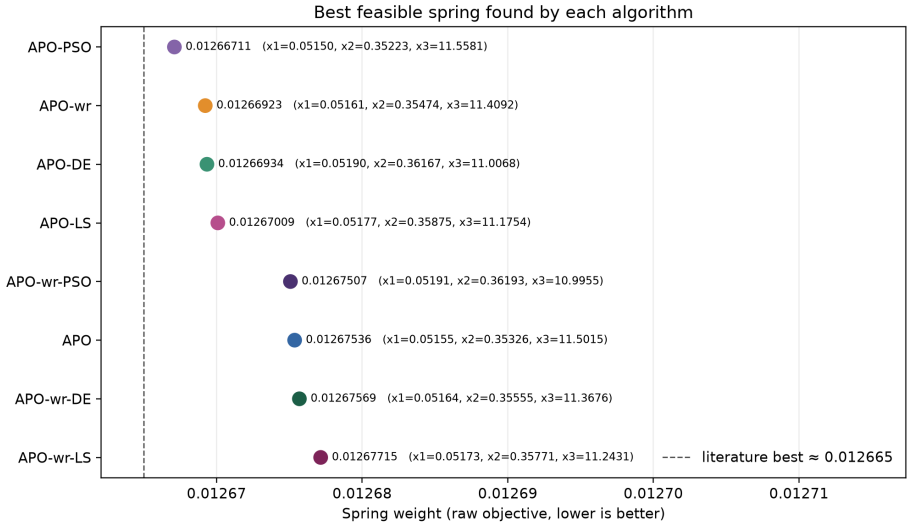
Všetky algoritmy výrazne zlepšujú hodnotu fitness najmä v úvodnej fáze optimalizácie. Približne po 1 000 až 1 500 vyhodnoteniach sa mediánové krivky približujú a rozdiely medzi nimi sú menšie. Detailný graf zachytáva počiatočnú fázu, zatiaľ čo tabuľka 1 uvádza finálne výsledky po celom výpočtovom rozpočte.

Pri párovom porovnaní pomocou Wilcoxonovho testu s Holmovou korekciou bolo štatisticky významných 11 z 28 porovnaní na hladine $\alpha = 0{,}05$. Oproti základnému APO dosiahli štatisticky významne lepšie výsledky varianty APO-DE ($p_{\text{Holm}} = 0{,}000349$) a APO-wr-DE ($p_{\text{Holm}} = 0{,}0000455$). Pri ostatných piatich variantoch sa štatisticky významný rozdiel oproti APO nepreukázal.

6.3 Porovnanie s výsledkami autorov

Autori pôvodného článku uvádzajú pre návrh tlačnej pružiny najlepšiu hodnotu 0.01266529 [1]. Najlepší výsledok tejto práce, dosiahnutý variantom APO-PSO, predstavuje 0.01266711. Rozdiel medzi týmito hodnotami je približne 0.00000182.

Obrázok 3 porovnáva najlepšie prípustné riešenia jednotlivých variantov s referenčnou hodnotou z pôvodnej štúdie. Referenčná čiara v grafe je zaokrúhlená na hodnotu 0.012665. Všetky varianty dosiahli výsledky blízke publikovanej hodnote, pričom najnižšiu hodnotu spomedzi našich algoritmov dosiahol APO-PSO.



Obr. 3: Najlepšie prípustné riešenia jednotlivých algoritmov v porovnaní s referenčnou hodnotou z článku [1].

Pri interpretácii je potrebné zohľadniť odlišné experimentálne podmienky. Autori použili 31 behov, populáciu 100 jedincov a 500 iterácií. V tejto práci sa uskutočnilo 30 behov so 100 jedincami a rozpočtom 10 000 vyhodnotení fitness na beh.

Dosiahnutý výsledok je blízky publikovanej hodnote, ale vzhľadom na rozdielny výpočtový rozpočet a možné odlišnosti v penalizácii obmedzení nejde o priamo ekvivalentné experimentálne porovnanie.

7 Diskusia a obmedzenia

Experimentálne výsledky ukazujú, že jednotlivé modifikácie algoritmu APO majú rozdielny vplyv na kvalitu a stabilitu optimalizácie. Variant APO-PSO dosiahol najlepšie jednotlivé riešenie, avšak jeho priemerná hodnota fitness bola horšia než pri základnom APO. To poukazuje na význam opakovaných behov a hodnotenia stability stochastických algoritmov.

Najlepší priemer a najnižšiu smerodajnú odchýlku dosiahol variant APO-wr-DE. Výsledky naznačujú, že kombinácia váh založených na poradí jedincov a diferenciálnej evolúcie môže byť pre skúmanú úlohu prínosná. Túto interpretáciu podporuje aj štatistické porovnanie so základným APO. Naopak, samotné pridanie mechanizmov lokálneho vyhľadávania alebo PSO nezaručilo zlepšenie priemerných výsledkov.

Významným obmedzením práce je testovanie na jedinej optimalizačnej úlohe. Získané závery preto nemožno automaticky zovšeobecniť na iné problémy. V porovnaní s pôvodnou štúdiou bol použitý menší výpočtový rozpočet a nie je potvrdená úplná zhoda spôsobu penalizácie obmedzení. Zároveň nebol samostatne meraný čas výpočtu jednotlivých algoritmov.

Ďalší výskum by mohol zahŕňať testovanie na viacerých optimalizačných úlohách, analýzu citlivosti na parametre a porovnanie pri rôznych výpočtových rozpočtoch.

8 Záver

Cieľom práce bolo analyzovať optimalizačnú úlohu návrhu tlačnej pružiny a experimentálne porovnať pôvodný algoritmus Artificial Protozoa Optimizer so siedmimi jeho modifikáciami. Všetky varianty boli implementované v jazyku Python a testované pri rovnakom výpočtovom rozpočte.

Experimenty ukázali, že najlepšie jednotlivé riešenie dosiahol variant APO-PSO, zatiaľ čo APO-wr-DE dosiahol najlepší priemer a najnižšiu smerodajnú odchýlku z 30 behov. Štatistické porovnanie potvrdilo významné zlepšenie variantov APO-DE a APO-wr-DE oproti základnému APO.

Výsledky poukazujú na potenciál kombinácie algoritmu APO s mechanizmami diferenciálnej evolúcie. Zistenia sú však obmedzené na jednu optimalizačnú úlohu a zvolený výpočtový rozpočet. Práca tak ukazuje význam systematického experimentálneho porovnávania nielen podľa najlepšieho riešenia, ale aj podľa stability a štatistickej významnosti výsledkov.

Literatúra

[1] Xiaopeng Wang, Václav Snášel, Seyedali Mirjalili, Jeng-Shyang Pan, Lingping Kong, and Hisham A. Shehadeh. Artificial protozoa optimizer (apo): A novel bio-inspired metaheuristic algorithm for engineering optimization. *Knowledge-Based Systems*, 295:111737, 2024.