Technická univerzita v Košiciach

Fakulta elektrotechniky a informatiky

Predmet: Moderné prístupy v optimalizácii

Artificial Protozoa Optimizer

Zadanie č. 1

Autori:
Volodymyr Ihnatov
Volodymyr Vulchyn
Nika Meskhi

Študijný program:
Umelá inteligencia

Košice, 2026

Abstrakt

Táto práca sa zaoberá analýzou a experimentálnym riešením optimalizačnej úlohy návrhu tlačnej pružiny pomocou algoritmu Artificial Protozoa Optimizer (APO) a jeho siedmich modifikácií. Cieľom je porovnať kvalitu a stabilitu riešení pri rovnakom výpočtovom rozpočte. Každý algoritmus bol testovaný v 30 behoch s rozpočtom 10 000 vyhodnotení fitness funkcie na jeden beh.

Najlepšie jednotlivé riešenie dosiahol variant APO-PSO, zatiaľ čo APO-wr-DE dosiahol najlepšiu priemernú hodnotu a najnižšiu smerodajnú odchýlku. Štatistické porovnanie pomocou Wilcoxonovho testu s Holmovou korekciou preukázalo významné zlepšenie variantov APO-DE a APO-wr-DE oproti základnému APO. Výsledky naznačujú prínos vybraných modifikácií pre skúmanú optimalizačnú úlohu.

Obsah

1 Úvod **2**

2 Optimalizačný problém **2**
2.1 Definícia a charakteristika problému 2
2.2 Rozhodovacie premenné a priestor riešení 2
2.3 Účelová funkcia a obmedzenia 3

3 Artificial Protozoa Optimizer **3**
3.1 Princíp algoritmu APO 3
3.2 Mechanizmy vyhľadávania 4

4 Implementácia a navrhnuté modifikácie **4**
4.1 Architektúra implementácie 4
4.2 Modifikácie algoritmu APO 4
4.3 Rozdiely oproti pôvodnému článku 5

5 Experimentálna metodológia **5**
5.1 Nastavenie experimentov 5
5.2 Hodnotiace metriky a štatistické testy 6
5.3 Reprodukovateľnosť experimentov 6

6 Výsledky a porovnanie **6**
6.1 Numerické výsledky 6
6.2 Analýza konvergencie a štatistické porovnanie 7
6.3 Porovnanie s výsledkami autorov 9

7 Diskusia a obmedzenia **9**

8 Záver **10**

1 Úvod

Optimalizácia zohráva významnú úlohu pri riešení technických a inžinierskych problémov, pri ktorých je potrebné nájsť čo najlepšie riešenie pri dodržaní stanovených obmedzení. Mnohé optimalizačné úlohy sú nelineárne a obsahujú viacero lokálnych extrémov, preto sa na ich riešenie využívajú aj metaheuristické algoritmy.

Jedným z takýchto algoritmov je Artificial Protozoa Optimizer (APO), ktorý predstavili Wang a kol. v roku 2024 [1]. Algoritmus je inšpirovaný správaním jednobunkových organizmov a využíva mechanizmy získavania potravy, dormancie a reprodukcie na vyhľadávanie kvalitných riešení. Jeho účinnosť bola v pôvodnej štúdii overená na štandardných testovacích funkciách a viacerých inžinierskych optimalizačných úlohách.

Cieľom tejto práce je analyzovať optimalizačný problém návrhu tlačnej pružiny a experimentálne porovnať pôvodný algoritmus APO so siedmimi jeho modifikáciami. Navrhnuté varianty využívajú váhy založené na poradí kandidátov, diferenciálnu evolúciu, lokálne vyhľadávanie a optimalizáciu rojom častíc. Jednotlivé algoritmy sú porovnané pri rovnakom výpočtovom rozpočte s dôrazom na kvalitu nájdených riešení, ich stabilitu a priebeh konvergencie.

2 Optimalizačný problém

2.1 Definícia a charakteristika problému

V tejto práci sa rieši optimalizačná úloha návrhu tlačnej vinutej pružiny (angl. tension/compression spring design), ktorá patrí medzi inžinierske problémy skúmané v pôvodnom článku o algoritme APO [1]. Cieľom je minimalizovať účelovú funkciu súvisiacu so spotrebou materiálu pružiny prostredníctvom vhodnej voľby jej geometrických parametrov pri súčasnom dodržaní konštrukčných a mechanických obmedzení.

Z matematického hľadiska ide o jednokriteriálnu, minimalizačnú, nelineárnu a spojitú optimalizačnú úlohu s obmedzeniami. Účelová funkcia a obmedzenia sú deterministické a počas optimalizácie sa nemenia, preto je úloha statická. Matematický model je explicitne definovaný, pričom algoritmus APO využíva hodnoty účelovej funkcie bez potreby výpočtu jej derivácií.

2.2 Rozhodovacie premenné a priestor riešení

Kandidátne riešenie je reprezentované vektorom troch reálnych rozhodovacích premenných:

$$\mathbf{x} = (x_1, x_2, x_3) = (d, D, N), \tag{1}$$

kde jednotlivé premenné predstavujú:

- $x_1 = d$ – priemer drôtu pružiny,
- $x_2 = D$ – stredný priemer vinutia pružiny,
- $x_3 = N$ – počet aktívnych závitov.

Označenia x_1, x_2 a x_3 sa používajú pri zobrazovaní numerických výsledkov a grafov, zatiaľ čo označenia d, D a N sa používajú v matematickom modeli optimalizačnej úlohy. Hoci počet závitov môže mať v praxi diskrétny charakter, v použitej matematickej formulácii sa považuje za spojitú premennú.

Hranice rozhodovacích premenných sú v implementácii stanovené nasledovne:

$$\begin{aligned} 0{,}05 \leq d \leq 2{,}0, \\ 0{,}25 \leq D \leq 1{,}3, \\ 2{,}0 \leq N \leq 15{,}0. \end{aligned} \tag{2}$$

Priestor vyhľadávania tvorí trojrozmerná oblasť $\Omega = [0{,}05; 2{,}0] \times [0{,}25; 1{,}3] \times [2{,}0; 15{,}0]$. Nie každé riešenie z tejto oblasti je však prípustné, pretože musí zároveň spĺňať mechanické a konštrukčné obmedzenia uvedené v nasledujúcej podkapitole.

2.3 Účelová funkcia a obmedzenia

Cieľom optimalizácie je minimalizovať účelovú funkciu, ktorá predstavuje matematický model spotreby materiálu pri návrhu pružiny. Hodnota funkcie závisí od priemeru drôtu d, stredného priemeru vinutia D a počtu aktívnych závitov N.

Optimalizačná úloha je definovaná ako minimalizácia účelovej funkcie $f(\mathbf{x})$ pri súčasnom splnení štyroch nelineárnych obmedzení $g_i(\mathbf{x}) \leq 0$, $i = 1, \ldots, 4$.

V použitej implementácii má účelová funkcia tvar

$$f(\mathbf{x}) = (N + 2)Dd^2. \tag{3}$$

Prípustné riešenia musia spĺňať nasledujúce štyri nelineárne obmedzenia:

$$g_1(\mathbf{x}) = 1 - \frac{D^3 N}{71785 d^4} \leq 0, \tag{4}$$

$$g_2(\mathbf{x}) = \frac{4D^2 - dD}{12566(Dd^3 - d^4)} + \frac{1}{5108 d^2} - 1 \leq 0, \tag{5}$$

$$g_3(\mathbf{x}) = 1 - \frac{140{,}45 d}{D^2 N} \leq 0, \tag{6}$$

$$g_4(\mathbf{x}) = \frac{d + D}{1{,}5} - 1 \leq 0. \tag{7}$$

Funkcie g_1, g_2, g_3 a g_4 predstavujú konštrukčné a mechanické obmedzenia návrhu pružiny. Riešenie je prípustné, ak sú všetky štyri hodnoty menšie alebo rovné nule.

Keďže algoritmus APO pracuje s hodnotou fitness, porušenie obmedzení sa zohľadňuje pomocou penalizačnej funkcie

$$F(\mathbf{x}) = f(\mathbf{x}) + 10^6 \sum_{i=1}^{4} \left[\max(0, g_i(\mathbf{x}))\right]^2. \tag{8}$$

Funkcia $f(\mathbf{x})$ predstavuje pôvodnú účelovú funkciu, zatiaľ čo $F(\mathbf{x})$ označuje penalizovanú hodnotu fitness, ktorú algoritmus minimalizuje.

Koeficient 10^6 určuje váhu penalizácie za porušenie obmedzení. Pre každé obmedzenie sa zohľadňuje iba jeho kladné porušenie, ktoré sa následne umocní na druhú.

Ak kandidátne riešenie spĺňa všetky obmedzenia, penalizácia je nulová a platí $F(\mathbf{x}) = f(\mathbf{x})$. V opačnom prípade sa hodnota fitness zvýši podľa veľkosti porušenia jednotlivých obmedzení.

3 Artificial Protozoa Optimizer

3.1 Princíp algoritmu APO

Artificial Protozoa Optimizer (APO) je populačný stochastický metaheuristický algoritmus, ktorý navrhli Wang a kol. [1]. Je inšpirovaný správaním jednobunkových organizmov, najmä euglén, pri získavaní potravy, prežívaní nepriaznivých podmienok a rozmnožovaní.

Každý jedinec populácie predstavuje kandidátne riešenie optimalizačnej úlohy, reprezentované vektorom rozhodovacích premenných. Populácia sa inicializuje náhodne v rámci stanovených hraníc. V každej iterácii sa jedince zoradia podľa hodnoty fitness a vytvárajú nové kandidátne riešenia pomocou mechanizmov získavania potravy, dormancie a reprodukcie. Nové riešenie nahradí pôvodné iba vtedy, ak dosahuje lepšiu hodnotu fitness.

3.2 Mechanizmy vyhľadávania

Získavanie potravy (*foraging*) zahŕňa dva režimy. Autotrofný režim umožňuje preskúmavať rôzne oblasti priestoru riešení na základe vzájomných pozícií jedincov. Heterotrofný režim podporuje vyhľadávanie v okolí aktuálneho riešenia. Pri aktualizácii pozícií sa využívajú váhy odvodené z hodnôt fitness a informácie o poradí jedincov v populácii.

Dormancia (*dormancy*) predstavuje mechanizmus, pri ktorom sa vybranému jedincovi vytvorí nové náhodné riešenie v priestore vyhľadávania. Tento proces podporuje diverzitu populácie a pomáha predchádzať predčasnej konvergencii.

Reprodukcia (*reproduction*) vytvára nové kandidátne riešenie náhodnou zmenou vybraných súradníc existujúceho jedinca. Umožňuje tak preskúmavať ďalšie riešenia v nadväznosti na aktuálnu populáciu.

Pravdepodobnosti jednotlivých mechanizmov sa menia v závislosti od iterácie alebo poradia jedinca v populácii. Algoritmus tak kombinuje prieskum nových oblastí (*exploration*) s intenzívnejším vyhľadávaním sľubných riešení (*exploitation*).

4 Implementácia a navrhnuté modifikácie

4.1 Architektúra implementácie

Riešenie bolo implementované v jazyku Python. Knižnica NumPy sa využíva na numerické výpočty a prácu s populáciou kandidátnych riešení, SciPy na štatistické vyhodnotenie experimentov a Matplotlib na vizualizáciu výsledkov.

Základ algoritmu APO je sústredený v súbore `algorithms/apo.py`, pričom jednotlivé modifikácie sú implementované v samostatných moduloch. Optimalizačná úloha návrhu pružiny je definovaná v súbore `algorithms/spring_design.py`, ktorý obsahuje účelovú funkciu, obmedzenia a výpočet penalizovanej hodnoty fitness.

Experimenty sa spúšťajú prostredníctvom skriptu `algorithms/run_experiments.py`. Výsledky experimentov sa ukladajú do adresára `results_all` vo formáte CSV.

4.2 Modifikácie algoritmu APO

Okrem základného algoritmu APO bolo implementovaných sedem modifikovaných variantov. Ich cieľom je preskúmať vplyv rôznych vyhľadávacích mechanizmov na kvalitu, stabilitu a konvergenciu optimalizácie.

Variant **APO-wr** nahrádza pôvodné váhy odvodené z hodnôt fitness váhami založenými na poradí jedincov v populácii. Cieľom je preskúmať vplyv relatívneho poradia riešení na výpočet vplyvu susedných jedincov.

Variant **APO-DE** využíva operátory diferenciálnej evolúcie DE/rand/1/bin na vytváranie nových kandidátnych riešení. Cieľom je podporiť prehľadávanie priestoru pomocou rozdielov medzi jedincami populácie.

Variant **APO-LS** využíva lokálne vyhľadávanie v okolí najlepšieho riešenia. Nové kandidátne riešenia vznikajú pomocou náhodných perturbácií, ktorých rozsah sa v priebehu optimalizácie zmenšuje. Cieľom je intenzívnejšie preskúmať perspektívne oblasti priestoru riešení.

Variant **APO-PSO** využíva aktualizáciu pozícií inšpirovanú optimalizáciou rojom častíc. Pri generovaní kandidátov zohľadňuje osobné najlepšie riešenie a globálne najlepšie riešenie populácie.

Ďalšie tri varianty, **APO-wr-DE**, **APO-wr-LS** a **APO-wr-PSO**, kombinujú váhy založené na poradí jedincov s príslušným vyhľadávacím mechanizmom. Ich cieľom je overiť, či kombinácia dvoch úprav prináša zlepšenie oproti samostatným modifikáciám.

Upravené operátory nahrádzajú generovanie vybraných kandidátov v rámci existujúcej iterácie. Modifikované varianty preto nevyžadujú dodatočné vyhodnotenia fitness nad rámec spoločného výpočtového rozpočtu.

4.3 Rozdiely oproti pôvodnému článku

Pôvodný algoritmus Artificial Protozoa Optimizer bol navrhnutý Wangom a kol. [1]. Jeho základ tvoria mechanizmy autotrofného a heterotrofného získavania potravy, dormancie a reprodukcie. Tieto mechanizmy spolu s populačným prístupom a výberom kandidátov podľa hodnoty fitness predstavujú základ implementácie v tejto práci.

Na rozdiel od pôvodného článku sú ostatné varianty navrhnuté ako rozšírenia v rámci tohto projektu. Ich pôvod a hlavné odlišnosti uvádza tabuľka 1.

Tabuľka 1: Pôvod a hlavné úpravy porovnávaných algoritmov.

Algoritmus	Pôvod	Hlavná úprava
APO	Paper algorithm	Pôvodné mechanizmy APO
APO-wr	Project extension	Váhy podľa poradia
APO-DE	Project extension	Diferenciálna evolúcia
APO-LS	Project extension	Lokálne vyhľadávanie
APO-PSO	Project extension	PSO aktualizácia
APO-wr-DE	Hybrid variant	APO-wr + DE
APO-wr-LS	Hybrid variant	APO-wr + LS
APO-wr-PSO	Hybrid variant	APO-wr + PSO

Označenie *Paper algorithm* predstavuje základný algoritmus opísaný v pôvodnom článku. Označenie *Project extension* označuje samostatnú úpravu vytvorenú v rámci projektu. Označenie *Hybrid variant* predstavuje kombináciu dvoch projektových modifikácií.

Algoritmy APO-DE, APO-LS a APO-PSO nie sú samostatnými variantmi navrhnutými autormi pôvodného článku. Rovnako kombinácie APO-wr-DE, APO-wr-LS a APO-wr-PSO predstavujú vlastné hybridné varianty projektu.

V pôvodnej štúdii bol algoritmus APO vyhodnotený na testovacích funkciách CEC2022, viacerých inžinierskych úlohách a úlohe segmentácie obrazu. Táto práca sa sústreďuje výlučne na optimalizáciu návrhu tlačnej pružiny.

Nejde preto o úplnú reprodukciu experimentálnej časti pôvodného článku, ale o kontrolované porovnanie ôsmich variantov na jednej vybranej inžinierskej optimalizačnej úlohe.

Experimenty boli uskutočnené s menším výpočtovým rozpočtom než v pôvodnej štúdii. Na zabezpečenie porovnateľných podmienok všetkých osem variantov využíva rovnakú účelovú funkciu, obmedzenia, veľkosť populácie a počet vyhodnotení fitness.

Podrobné nastavenie experimentov je uvedené v nasledujúcej kapitole.

5 Experimentálna metodológia

5.1 Nastavenie experimentov

Experimenty boli vykonané na úlohe optimalizácie návrhu tlačnej pružiny s cieľom porovnať pôvodný algoritmus APO so siedmimi modifikovanými variantmi. Všetkých osem algoritmov používalo rovnakú účelovú funkciu, obmedzenia, priestor riešení a výpočtový rozpočet.

Pre každý algoritmus sa uskutočnilo 30 nezávislých spustení s populáciou 100 jedincov a 100 generáciami vrátane inicializácie. Jedno spustenie zahŕňalo 10 000 vyhodnotení fitness funkcie. Parametre APO boli nastavené na $np = 1$ a $pf_{\max} = 0{,}1$.

V modifikáciách sa operátor DE aplikoval na 20 % kandidátov s faktorom diferenciálnej mutácie $F_{\mathrm{DE}} = 0{,}5$ a pravdepodobnosťou kríženia $CR = 0{,}9$. Lokálne vyhľadávanie sa používalo pre 10 % populácie so základnou mierkou perturbácie 0,1. Mechanizmus PSO sa aplikoval na 10 %

kandidátov. Kombinované varianty využívali príslušné nastavenia spolu s váhami založenými na poradí jedincov.

5.2 Hodnotiace metriky a štatistické testy

Kvalita algoritmov sa hodnotila na základe penalizovanej hodnoty fitness dosiahnutej na konci každého spustenia. Pre jednotlivé algoritmy sa vypočítala najlepšia a najhoršia hodnota, aritmetický priemer, medián a výberová smerodajná odchýlka z 30 behov.

Okrem kvality riešení sa sledovala konvergencia najlepšej nájdenej hodnoty fitness v závislosti od počtu jej vyhodnotení. Prípustnosť riešení sa posudzovala podľa celkového porušenia obmedzení s toleranciou 10^{-8}. Podiel prípustných finálnych riešení bol vyjadrený metrikou *feasible rate*.

Na porovnanie dvojíc algoritmov sa použil obojstranný párový Wilcoxonov test. Pri celkovo 28 párových porovnaniach sa p-hodnoty upravili Holmovou korekciou na hladine významnosti $\alpha = 0{,}05$.

5.3 Reprodukovateľnosť experimentov

Na zabezpečenie reprodukovateľnosti boli použité pevne určené počiatočné stavy generátora pseudonáhodných čísel. Pre k-té spustenie, kde $k = 1, \ldots, 30$, bol použitý seed

$$s_k = 2022 + 7(k - 1). \tag{9}$$

Pred každým spustením algoritmu bol generátor náhodných čísel inicializovaný príslušnou hodnotou seed. Všetky varianty tak boli testované s rovnakou sadou 30 počiatočných stavov.

Experimenty možno spustiť skriptom `run_experiments.py`. Výsledky sa ukladajú do súborov `runs.csv`, `convergence.csv`, `summary.csv` a `statistics.csv`. Návod na prípravu prostredia a spustenie experimentov je uvedený v súbore `README.md` projektu.

6 Výsledky a porovnanie

6.1 Numerické výsledky

Experimenty pozostávali z 30 behov pre každý z ôsmich algoritmov. Tabuľka 2 uvádza najlepšiu a najhoršiu dosiahnutú hodnotu, aritmetický priemer, medián a výberovú smerodajnú odchýlku penalizovanej fitness funkcie. Nižšie hodnoty predstavujú lepšie riešenia.

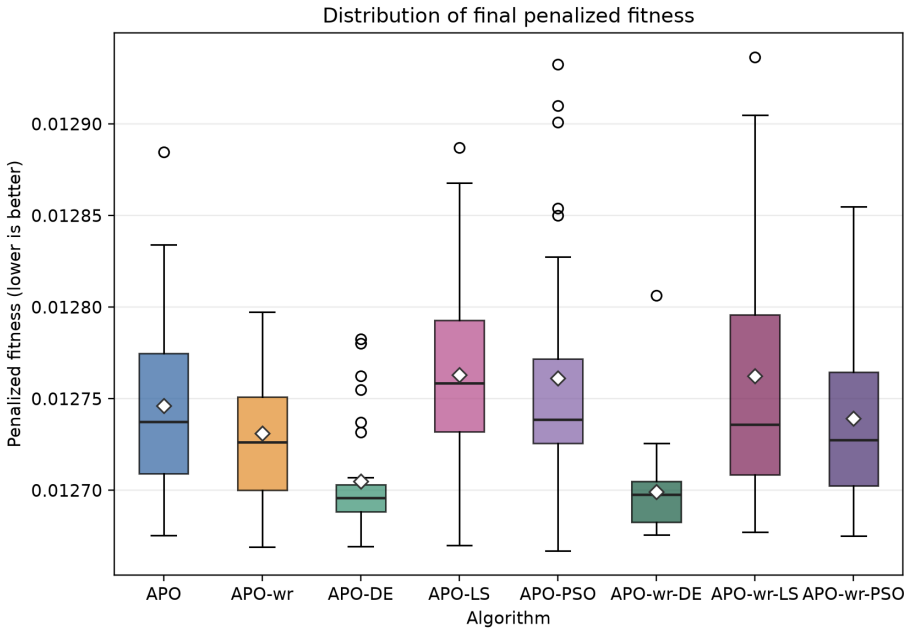
Tabuľka 2: Výsledky optimalizácie pružiny z 30 behov.

Algoritmus	Najlepšia	Najhoršia	Priemer	Medián	Sm. odch.
APO	0.01267536	0.01288472	0.01274621	0.01273738	0.00004970
APO-wr	0.01266923	0.01279728	0.01273098	0.01272631	0.00003680
APO-DE	0.01266934	**0.01278260**	0.01270478	**0.01269593**	0.00002991
APO-LS	0.01267009	0.01288719	0.01276302	0.01275840	0.00005543
APO-PSO	**0.01266711**	0.01293252	0.01276117	0.01273873	0.00006869
APO-wr-DE	0.01267569	0.01280638	**0.01269914**	0.01269757	**0.00002467**
APO-wr-LS	0.01267715	0.01293638	0.01276240	0.01273600	0.00007676
APO-wr-PSO	0.01267507	0.01285487	0.01273928	0.01272753	0.00004889

Najlepšiu jednotlivú hodnotu fitness dosiahol algoritmus APO-PSO (0.01266711). Najlepší priemer (0.01269914) a zároveň najnižšiu smerodajnú odchýlku dosiahol variant APO-wr-DE. Základný APO dosiahol priemernú hodnotu 0.01274621. Všetkých osem algoritmov dosiahlo 100 % prípustných finálnych riešení pri použitej tolerancii obmedzení.

Rozdelenie finálnych hodnôt fitness znázorňuje obrázok 1. Krabicové diagramy umožňujú porovnať medián a variabilitu výsledkov jednotlivých algoritmov. Variant APO-wr-DE dosahuje

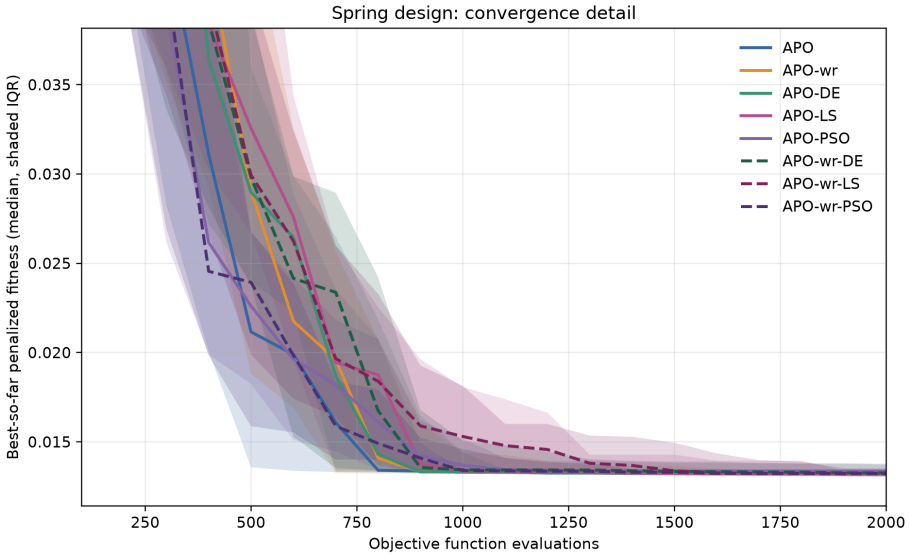
nízke finálne hodnoty s relatívne malým rozptylom, zatiaľ čo niektoré varianty s mechanizmami LS a PSO vykazujú vyššiu variabilitu.



Obr. 1: Rozdelenie finálnych hodnôt fitness ôsmich algoritmov počas 30 behov.

6.2 Analýza konvergencie a štatistické porovnanie

Obrázok 2 zobrazuje priebeh konvergencie počas prvých 2 000 vyhodnotení fitness funkcie. Krivky predstavujú medián najlepšej dosiahnutej hodnoty z 30 behov a tieňované oblasti interval medzi 25. a 75. percentilom.



Obr. 2: Detail konvergencie ôsmich algoritmov počas prvých 2 000 vyhodnotení fitness; medián a interval medzi 25. a 75. percentilom.

Všetky algoritmy výrazne zlepšujú hodnotu fitness najmä v úvodnej fáze optimalizácie. Približne po 1 000 až 1 500 vyhodnoteniach sa mediánové krivky približujú a rozdiely medzi nimi sú menšie. Detailný graf zachytáva počiatočnú fázu, zatiaľ čo tabuľka 2 uvádza finálne výsledky po celom výpočtovom rozpočte.

Pri párovom porovnaní pomocou obojstranného Wilcoxonovho testu s Holmovou korekciou bolo štatisticky významných 11 z 28 porovnaní na hladine $\alpha = 0{,}05$. Výsledky všetkých párových porovnaní sú uvedené v tabuľke 3.

Tabuľka 3: Výsledky párového Wilcoxonovho testu s Holmovou korekciou.

Porovnanie	W	p	p_{Holm}	Význ.
APO vs APO-wr	177	0.262122	1.000000	Nie
APO vs APO-DE	39	0.000014	0.000349	Áno
APO vs APO-LS	187	0.359878	1.000000	Nie
APO vs APO-PSO	182	0.308521	1.000000	Nie
APO vs APO-wr-DE	25	0.000002	0.000045	Áno
APO vs APO-wr-LS	186	0.349211	1.000000	Nie
APO vs APO-wr-PSO	211	0.670181	1.000000	Nie
APO-wr vs APO-DE	68	0.000380	0.007222	Áno
APO-wr vs APO-LS	130	0.034537	0.552588	Nie
APO-wr vs APO-PSO	130	0.034537	0.552588	Nie
APO-wr vs APO-wr-DE	90	0.002560	0.046082	Áno
APO-wr vs APO-wr-LS	166	0.177193	1.000000	Nie
APO-wr vs APO-wr-PSO	213	0.700033	1.000000	Nie
APO-DE vs APO-LS	38	0.000012	0.000317	Áno
APO-DE vs APO-PSO	59	0.000153	0.003363	Áno
APO-DE vs APO-wr-DE	205	0.583757	1.000000	Nie
APO-DE vs APO-wr-LS	47	0.000039	0.000937	Áno
APO-DE vs APO-wr-PSO	109	0.009932	0.168836	Nie
APO-LS vs APO-PSO	208	0.626346	1.000000	Nie
APO-LS vs APO-wr-DE	21	0.000001	0.000023	Áno
APO-LS vs APO-wr-LS	221	0.823577	1.000000	Nie
APO-LS vs APO-wr-PSO	160	0.140283	1.000000	Nie
APO-PSO vs APO-wr-DE	47	0.000039	0.000937	Áno
APO-PSO vs APO-wr-LS	214	0.715133	1.000000	Nie
APO-PSO vs APO-wr-PSO	151	0.096102	1.000000	Nie
APO-wr-DE vs APO-wr-LS	63	0.000232	0.004864	Áno
APO-wr-DE vs APO-wr-PSO	63	0.000232	0.004864	Áno
APO-wr-LS vs APO-wr-PSO	177	0.262122	1.000000	Nie

Párové porovnania vychádzali z finálnych hodnôt fitness získaných pri rovnakých 30 počiatočných stavoch generátora pseudonáhodných čísel.

V tabuľke W označuje Wilcoxonovu testovú štatistiku, p pôvodnú p-hodnotu a p_{Holm} p-hodnotu upravenú Holmovou korekciou. Označenie Áno znamená štatisticky významný rozdiel pri $\alpha = 0{,}05$.

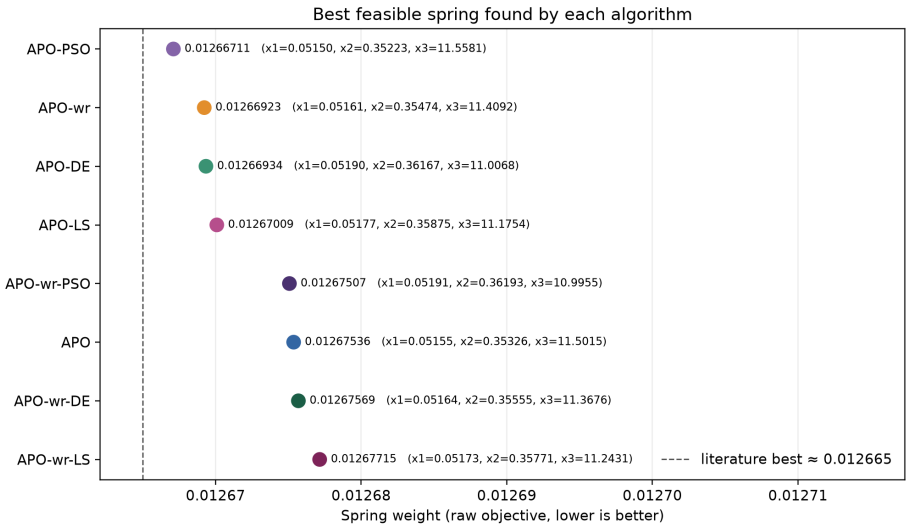
Oproti základnému APO dosiahli štatisticky významne lepšie výsledky varianty APO-DE ($p_{\text{Holm}} = 0{,}000349$) a APO-wr-DE ($p_{\text{Holm}} = 0{,}0000455$). Pri ostatných piatich variantoch sa štatisticky významný rozdiel oproti základnému APO nepreukázal.

Výsledky zároveň ukazujú, že medzi variantmi APO-DE a APO-wr-DE nebol preukázaný štatisticky významný rozdiel ($p_{\text{Holm}} = 1$), hoci APO-wr-DE dosiahol nižší priemer a smerodajnú odchýlku.

6.3 Porovnanie s výsledkami autorov

Autori pôvodného článku uvádzajú pre návrh tlačnej pružiny najlepšiu hodnotu 0.01266529 [1]. Najlepší výsledok tejto práce, dosiahnutý variantom APO-PSO, predstavuje 0.01266711. Rozdiel medzi týmito hodnotami je približne 0.00000182.

Obrázok 3 porovnáva najlepšie prípustné riešenia jednotlivých variantov s referenčnou hodnotou z pôvodnej štúdie. Referenčná čiara v grafe je zaokrúhlená na hodnotu 0.012665. Všetky varianty dosiahli výsledky blízke publikovanej hodnote, pričom najnižšiu hodnotu spomedzi našich algoritmov dosiahol APO-PSO.



Obr. 3: Najlepšie prípustné riešenia jednotlivých algoritmov v porovnaní s referenčnou hodnotou z článku [1].

Pri interpretácii je potrebné zohľadniť odlišné experimentálne podmienky. Autori použili 31 behov, populáciu 100 jedincov a 500 iterácií. V tejto práci sa uskutočnilo 30 behov so 100 jedincami a rozpočtom 10 000 vyhodnotení fitness na beh.

Dosiahnutý výsledok je blízky publikovanej hodnote, ale vzhľadom na rozdielny výpočtový rozpočet a možné odlišnosti v penalizácii obmedzení nejde o priamo ekvivalentné experimentálne porovnanie.

Hlavným cieľom experimentov v tejto práci je preto vzájomné porovnanie ôsmich implementovaných variantov pri rovnakých podmienkach, nie úplná reprodukcia experimentov pôvodnej štúdie.

7 Diskusia a obmedzenia

Experimentálne výsledky ukazujú, že jednotlivé modifikácie algoritmu APO majú rozdielny vplyv na kvalitu a stabilitu optimalizácie. Variant APO-PSO dosiahol najlepšie jednotlivé riešenie, avšak jeho priemerná hodnota fitness bola horšia než pri základnom APO. To poukazuje na význam opakovaných behov a hodnotenia stability stochastických algoritmov.

Najlepší priemer a najnižšiu smerodajnú odchýlku dosiahol variant APO-wr-DE. Výsledky naznačujú, že kombinácia váh založených na poradí jedincov a diferenciálnej evolúcie môže byť pre skúmanú úlohu prínosná. Túto interpretáciu podporuje aj štatistické porovnanie so základným APO. Naopak, samotné pridanie mechanizmov lokálneho vyhľadávania alebo PSO nezaručilo zlepšenie priemerných výsledkov.

Významným obmedzením práce je testovanie na jedinej optimalizačnej úlohe. Získané závery preto nemožno automaticky zovšeobecniť na iné problémy. V porovnaní s pôvodnou štúdiou bol

použitý menší výpočtový rozpočet a nie je potvrdená úplná zhoda spôsobu penalizácie obmedzení. Zároveň nebol samostatne meraný čas výpočtu jednotlivých algoritmov.

Ďalší výskum by mohol zahŕňať testovanie na viacerých optimalizačných úlohách, analýzu citlivosti na parametre a porovnanie pri rôznych výpočtových rozpočtoch.

8 Záver

Cieľom práce bolo analyzovať optimalizačnú úlohu návrhu tlačnej pružiny a experimentálne porovnať pôvodný algoritmus Artificial Protozoa Optimizer so siedmimi jeho modifikáciami. Všetky varianty boli implementované v jazyku Python a testované pri rovnakom výpočtovom rozpočte.

Experimenty ukázali, že najlepšie jednotlivé riešenie dosiahol variant APO-PSO, zatiaľ čo APO-wr-DE dosiahol najlepší priemer a najnižšiu smerodajnú odchýlku z 30 behov. Štatistické porovnanie potvrdilo významné zlepšenie variantov APO-DE a APO-wr-DE oproti základnému APO.

Výsledky poukazujú na potenciál kombinácie algoritmu APO s mechanizmami diferenciálnej evolúcie. Zistenia sú však obmedzené na jednu optimalizačnú úlohu a zvolený výpočtový rozpočet. Práca tak ukazuje význam systematického experimentálneho porovnávania nielen podľa najlepšieho riešenia, ale aj podľa stability a štatistickej významnosti výsledkov.

Literatúra

[1] Xiaopeng Wang, Václav Snášel, Seyedali Mirjalili, Jeng-Shyang Pan, Lingping Kong, and Hisham A. Shehadeh. Artificial protozoa optimizer (apo): A novel bio-inspired metaheuristic algorithm for engineering optimization. *Knowledge-Based Systems*, 295:111737, 2024.